

矿井救援中基于多模态层级化条件融合的生命状态评估系统

张晶园 刘晨煜 李立星 孙凯文 潘红光 李清政 母庆鑫

引用本文:

张晶园, 刘晨煜, 李立星, 等. 矿井救援中基于多模态层级化条件融合的生命状态评估系统[J]. 煤炭科学技术, 2026, 54(4): 111–124.

ZHANG Jingyuan, LIU Chenyu, LI Lixing. Life status assessment system in mine rescue with multimodal hierarchical condition fusion[J]. Coal Science and Technology, 2026, 54(4): 111–124.

在线阅读 View online: <https://doi.org/10.12438/cst.2026-0112>

您可能感兴趣的其他文章

Articles you may be interested in

融合多级特征增强与权重网格统计的煤矿井下图像匹配

Coalmine image matching by fusing multi-level feature enhancement and weighted grid statistics

煤炭科学技术. 2024, 52(11): 129–140 <https://doi.org/10.12438/cst.2024-1224>

基于多尺度特征融合井下猴车载人状态的智能识别算法与应用

Intelligent recognition algorithm and application of coal mine overhead passenger device based on multiscale feature fusion

煤炭科学技术. 2024, 52(12): 272–286 <https://doi.org/10.12438/cst.2024-0081>

面向原煤分选场景的多模态融合异物开集检测方法

Multimodal fusion method for foreign object open-set detection in raw coal sorting scenario

煤炭科学技术. 2026, 54(1): 464–474 <https://doi.org/10.12438/cst.2025-1228>

基于多种图结构信息融合的刮板输送机健康状态识别

Health status identification of scraper conveyor based on fusion of multiple graph structure information

煤炭科学技术. 2024, 52(8): 171–181 <https://doi.org/10.12438/cst.2023-1557>

基于单激光束信息的掘锚装备视觉定位方法研究

Research on visual positioning method of digging and anchoring equipment based on single laser beam information

煤炭科学技术. 2024, 52(1): 311–322 <https://doi.org/10.12438/cst.2023-1674>

基于多模态大模型的井下视频语义提取与描述生成技术

Underground video semantic extraction and description generation technology based on multimodal large model

煤炭科学技术. 2025, 53(11): 216–228 <https://doi.org/10.12438/cst.2025-0940>



关注微信公众号, 获得更多资讯信息



移动扫码阅读

张晶园, 刘晨煜, 李立星, 等. 矿井救援中基于多模态层级化条件融合的生命状态评估系统[J]. 煤炭科学技术, 2026, 54(4): 111–124.

ZHANG Jingyuan, LIU Chenyu, LI Lixing, *et al.* Life status assessment system in mine rescue with multimodal hierarchical condition fusion[J]. Coal Science and Technology, 2026, 54(4): 111–124.

矿井救援中基于多模态层级化条件融合的生命状态评估系统

张晶园¹, 刘晨煜¹, 李立星¹, 孙凯文¹, 潘红光¹, 李清政², 母庆鑫³

(1. 西安科技大学 电气与控制工程学院, 陕西 西安 710054; 2. 西安天河矿业科技有限责任公司, 陕西 西安 710077;

3. 四川嘉华机械有限责任公司, 四川 华蓥 638600)

摘要:为解决矿井应急救援中在定位被困人员后难以快速、准确量化评估其生命状态(尤其是意识水平连续变化)的关键技术瓶颈, 研究并构建了一套基于多模态生理信息智能融合的生命状态评估系统。研究的核心在于, 摒弃通用特征迁移的传统范式, 针对“矿井灾后昏迷–低唤醒连续谱系评估”这一特定问题, 进行知识驱动的原生特征工程框架设计。系统同步采集脑电(Electroencephalogram, EEG)、心电(Electrocardiogram, ECG)与血氧(Peripheral Capillary Oxygen Saturation, SpO₂)信号, 并为其分别设计了深度专用的特征提取算法: 针对单通道前额 EEG 空间信息缺失的约束, 提出融合高分辨率时频分析、多尺度非线性动力学(如多尺度样本熵、递归定量分析)及瞬态波形形态学的“深度时序信息挖掘”框架; 针对 ECG 与 SpO₂, 则分别构建了以量化自主神经功能梯度和氧合趋势/负荷为核心的专用特征集。在此基础上, 进一步提出了层级化条件融合系统, 将“先评估生命体征、后评估意识状态”的临床先验知识结构化编码为网络架构, 实现了特征提取与融合决策的逻辑闭环。在基于公共数据集与自建“可唤醒”数据集(共 2 500 份样本)的测试中, 该系统对“可唤醒”“轻度昏迷”“重度昏迷”“近似死亡”4 类状态的平均评估准确率达到 94.90%, 召回率为 94.30%, 显著优于主流对比模型, 为极端受限环境下的精准生命状态评估提供了有效的算法和系统架构。

关键词: 多模态信息融合; 生命状态评估; 矿井应急救援; 特征提取; 层级化条件融合

中图分类号: TD77; TP391.4 **文献标志码:** A **文章编号:** 0253-2336(2026)04-0111-14

Life status assessment system in mine rescue with multimodal hierarchical condition fusion

ZHANG Jingyuan¹, LIU Chenyu¹, LI Lixing¹, SUN Kaiwen¹, PAN Hongguang¹, LI Qingzheng², MU Qingxin³

(1. College of Electrical and Control Engineering, Xi'an University of Science and Technology, Xi'an 710054, China; 2. Xi'an Tianhe

Mining Technology Co., Ltd., Xi'an 710077, China; 3. Sichuan Jiahua Machinery Co., Ltd., Huaying 638600, China)

Abstract: To address the critical technological bottleneck in mine emergency rescue—namely, the difficulty of rapidly and accurately quantifying the assessment of a trapped person's vital state (especially the continuous changes in consciousness level) after localization—this paper studies and constructs a vital state assessment system based on the intelligent fusion of multimodal physiological information. The core of this research lies in abandoning the traditional paradigm of general feature transfer and instead designing a knowledge-driven native feature engineering framework specifically for the specific problem of “assessing the coma-low arousal continuum spectrum post-mine disaster”. The system synchronously acquires electroencephalogram (EEG), electrocardiogram (ECG), and Peripheral Capillary Oxygen Saturation (SpO₂) signals, for which depth-specific feature extraction algorithms are respectively designed: To over-

收稿日期: 2026-01-19

策划编辑: 朱恩光

责任编辑: 陈思成

DOI: 10.12438/cst.2026-0112

基金项目: 国家重点研发计划资助项目(2024YFC3015703); 陕西省自然科学基金基础研究计划资助项目(2023-JC-QN-0452); 陕西省教育厅科学研究计划服务地方专项资助项目(24JR113)

作者简介: 张晶园(1984—), 女, 辽宁沈阳人, 讲师, 硕士生导师, 博士。E-mail: jy Zhang_tong@163.com

通讯作者: 潘红光(1983—), 男, 山东临沂人, 教授, 硕士生导师, 博士。E-mail: hongguangpan@xust.edu.cn

come the constraint of spatial information loss in single-channel forehead EEG, a “deep temporal information mining” framework is proposed, integrating high-resolution time-frequency analysis, multi-scale nonlinear dynamics (such as multi-scale sample entropy, recurrence quantification analysis), and transient waveform morphology. For ECG and SpO₂, dedicated feature sets centered on quantifying autonomic nervous function gradients and oxygenation trends/load are constructed, respectively. Building on this, the paper further proposes a hierarchical conditional fusion system, which structurally encodes the clinical prior knowledge of “assessing vital signs first, then assessing the state of consciousness” into the network architecture, achieving a logical closed loop for feature extraction and fusion decision-making. In tests based on public datasets and a self-built “Arousable” dataset (totaling 2 500 samples), the system achieved an average assessment accuracy of 94.90% and a recall rate of 94.30% for the four states: “arousable” “mild coma” “deep coma” and “near death”. This performance significantly outperforms mainstream comparative models, providing an effective algorithm and system architecture for precise vital state assessment in extremely restricted environments.

Key words: multimodal information fusion; life status assessment; mine emergency rescue; feature extraction; hierarchical conditional fusion

0 引言

目前,在矿山井下应急救援中,对被困人员的成功定位,标志着“搜”的阶段任务完成,并非救援行动的终结。随之而来的挑战在于如何快速、准确地掌握被定位者的生命状态,特别是那些因窒息、冲击或中毒已陷入昏迷、丧失自主应答能力的伤员。这一关键信息的缺失,使后续救援力量的投入、医疗资源的调配以及现场急救策略的制定,均面临严重的不确定性^[1-4]。传统依赖人工近距离探查(如触摸脉搏、观察呼吸)的方式,在井下复杂危险环境下不仅效率低下、风险高,更难以对昏迷深度及生理机能进行客观量化评估。因此,急需实现从“找到人”到“判明状态”的精准跨越。生命状态评估技术的意义,不仅在于判定“生”或“死”的二元状态,更在于通过对心电、脑电等多模态生理信号的深度解析,实现对昏迷深度、应激水平及潜在生命风险的早期预警与分级评估。这能为井上指挥中心提供动态的伤员生理态势图,支撑医疗救援力量的预先准备和最优投放,保障并构筑矿工生命安全防线。因此,探索基于多模态生物电信号融合的智能评估系统,可为矿山应急救援装备的智能化发展提供有效的解决方案。

然而,要在井下实现生命状态评估,信号的便携式采集是硬件基础,不同模态生物电信号的特征以及融合评估是关键。针对生理信号处理,基于深度学习的特征提取与融合方法已成为主流,其在提升信号鲁棒性与挖掘多模态关联方面取得了关键进展。信号处理和增强技术发展已经趋于成熟,很多研究致力于解决信号采集中的噪声、缺失问题。CHEN等^[5]提出 UniCardio 统一生成框架,能够对心电(ECG)等信号进行去噪、插补甚至跨模态合成;WANG等^[6]研究则实现了从脑电(EEG)到脑血氧信

号的跨模态表征生成,提升了信号质量与完整性;这些方法为在恶劣环境下获取可用数据提供了技术可能。深度特征提取的方式已经成为主流研究^[7],卷积神经网络(CNN)因其强大的空间特征提取能力,已成为处理 EEG、ECG 等波形信号的主流架构^[8-11]。研究显示,超过 90% 的基于深度学习的 EEG 分类研究采用或融合了 CNN 结构。上海交通大学团队开发的 BioCross 框架,也利用深度网络从 ECG、PPG 等信号中学习统一跨模态表示。尽管方法先进,但现有特征提取模型多为通用化设计,旨在最大化各类任务的总体性能。而矿山灾后昏迷人员的状态评估,要求特征必须与意识水平、自主神经衰竭、氧合障碍等特定生理危机直接关联。通用特征可能包含冗余信息,却遗漏对判断“可唤醒”与“轻度昏迷”至关重要的细微动力学特征。如何融合多模态信息是多模态研究的核心^[12-19]。在决策级融合方面,各模态独立处理至分类阶段,再整合结果^[12-14]。实现简单,容错性高。完全忽略模态间早期关联,无法实现生理意义上的互补增强。特征级融合方面,提取各模态特征后进行拼接或加权融合^[15-16]。能保留模态特性,是目前较主流的方法^[17-19]。当前研究多为简单式拼接,未能依据生理机制(如“心肺功能先于脑功能评估”)建立结构化的融合逻辑。输入级融合方面,原始信号早期拼接后统一处理。理论上能挖掘最原始的关联。易受不同信号采样率、尺度差异干扰,模型学习负担重。为改进简单融合,很多研究开始关注更精细的交互机制,有研究通过跨模态注意力机制动态校准不同模态特征的权重,或在潜在空间中对齐不同模态。近年来,为突破纯数据驱动模型的黑盒局限性与跨模态语义鸿沟,先验引导与知识驱动的多模态融合范式在医疗与健康信息学领域引起了广泛关注^[20]。研究者们开始尝试将临床诊断

逻辑、病理机制或医生经验作为先验知识,结构化地注入深度神经网络。例如,在最新的跨模态医疗数据分析中,前沿研究引入了临床先验引导的层级化融合架构,利用基础临床特征作为指导,对复杂的高维数据进行多尺度的特征对齐与提纯,显著提升了决策的可解释性^[21]。此外,在针对连续生理信号(如 EEG、ECG)的多模态特征交互探索上,最新算法也开始摒弃早期的扁平化拼接,转而采用具有深度交互和门控机制的层级融合策略,以克服不同生理信号间巨大的异质性与噪声干扰^[22]。现有先进融合策略虽能提升模型性能,但其设计本质是数据驱动的,即让模型从数据中自动发现关联。然而,矿山救援评估亟需一种知识引导的融合范式:即模拟急诊医学中“先评估生命体征(心/肺),再评估意识状态(脑)”的临床决策路径^[23-24]。将这种层次化、条件化的生理逻辑硬编码到融合架构中,而非完全依赖模型自行发现,是当前研究尚未系统解决的挑战。

面向矿井救援场景,强化生命状态特征提取的针对性,笔者通过设计面向单通道 EEG 的多路径深度特征提取器(时频、非线性、形态),及面向 ECG、SpO₂ 的专用特征提取方案,确保所提特征与灾后昏迷生命体征的精细变化高度相关,为评估提供科学的信息基础。另一方面,为了解决融合逻辑缺失的问题,笔者通过提出层级化条件融合模型,创新性地“先生存体征,后神经功能”的临床先验知识结构化嵌入模型。具体而言,先融合 ECG 与 SpO₂ 特征生成“生命维持状态”上下文,再以此条件指导 EEG 特征的融合与解读。这种条件化的融合机制,超越了简单的特征拼接或数据驱动的注意力分配,实现了符合生理与急救逻辑的智能评估。

1 系统总体框架

1.1 总体设计

基于脑电、心电及血氧多模态信息融合的生命状态评估系统,技术框图如图 1 所示。主要由硬件采集与智能分析两大模块构成。通过专用传感阵列同步采集 3 种原始生理信号,并由嵌入式核心控制器进行初步处理与传输,在终端平台进行计算分析。智能分析核心算法模型包含 3 个功能,首先针对各模态信号的专用特征提取(如脑电的时频与非线性分析、心电的 HRV 分析、血氧的趋势建模);其次模拟临床推理路径的层级化融合编码,即先融合心电与血氧特征评估“生命维持强度”,再以此结果为条件引导脑电特征的融合与解读。最终,系统输出对“可

唤醒”“轻度昏迷”“重度昏迷”及“近似死亡”4 种生命状态的分类结果,形成从数据采集到智能诊断的闭环系统设计。

1.2 硬件系统设计

1.2.1 主控单元

本文选用 FriendlyELEC CM3588 高性能计算模块作为主控单元,该模块尺寸约为 100.0 mm×85.5 mm×7.0 mm(长×宽×高),基于 Rockchip RK3588 处理器设计,采用工业级封装,可选配最高 16 GB LPDDR4X 内存,为现场多路数据并行处理提供强大支持。其独特的 big.LITTLE 架构能智能调配四核 Cortex-A76 与四核 Cortex-A55 的工作负载,在保障实时分析响应的同时,将工作功耗控制在 3~8 W,完美适配救援现场移动电源供电方案。

1.2.2 传感器模块

1) 脑电传感器模块。OpenBCI(Open-source Brain-Computer Interface, 开源脑机接口)脑电传感器是一个用于采集、处理和分析生物电信号(如脑电 EEG、肌电 EMG、眼电 EOG)的开源硬件与软件平台。其核心是通过接触头皮或皮肤的电极采集微弱的生物电信号,经过采集板(如 Cyton、Ganglion)进行放大、模数转换,通过有线或无线方式传输至计算机或嵌入式主控单元进行分析。其原理基于生物电现象,大脑皮层神经元的电活动会在头皮产生电位差,这些电位变化通过放置在头皮特定位置(遵循国际 10-20 系统)的电极被捕捉,形成脑电图。该平台不仅能用于基础的脑电波(如 Alpha 波)检测,还可用于识别眨眼、肌肉活动等多种生物特征信号,并可通过软件(如 OpenBCIGUI)进行实时可视化、滤波(如滤除 50 Hz 工频干扰)和数据分享。

2) 心电传感器模块。BMD101 模块是一款心率采集芯片,该芯片通过 2 个电极端进行测量。通过手指按住电极的两侧,芯片开启时会有手指导通的微电流。该芯片根据通过手指的微电流的变化,反馈出人体的心率变化。该芯片反馈出的是实时采集的心率数据,会出现上下波动的情况,可根据实时的心率数据进行绘图后,通过算法进行滤波和计算,最后得到完整稳定的人体心率变化曲线和基本人体心率平均值。

3) 血氧传感器模块。MKS-SPO₂-R 是一款高性能的血氧传感器模块,主要用于监测人体血氧饱和度和脉搏频率。该模块采用光电容积脉搏波描记法,通过发射和接收特定波长的光线来分析血液中的氧气含量。




图 1 系统技术框图

Fig.1 System technology block diagram

1.3 软件设计

本系统的核心功能是灾后伤亡人员的生命状态评估,旨在提高灾后救援效率。系统在采集区域设有 3 个数据采集模块,分别对应脑电、心电、血氧模块。软件核心任务是实现对脑电、心电、血氧 3 类生理数据的高效整合与实时评估,以支持灾后现场的生命状态快速判断。软件通过稳定的数据链路将各传感器数据接入中央处理单元,确保传输可靠性。针对不同数据特性进行专项预处理:对脑电信号进行 0.1 ~ 30.0 Hz 滤波并统一重采样至 125 Hz,提取有效段去除伪迹;对心电数据同步至 125 Hz 并截取关键波形段进行处理。整个系统采用模块化设计,通过标准接口连接各功能部分,便于未来扩展新的传感器或优化算法,从而在保障当前救援任务的同

时,保持系统的迭代能力。

在数据处理方面,系统采用了 CM3588 作为核心处理单元。该单元负责接收来自各个模块的数据,同时进行数据预处理和特征提取。通过对传感器传输的数据进行实时分析,基于多模态融合的监测和评估系统能够有效提取出相关的特征值。经过特征提取后,这些数据被输入到多模态融合模型中进行评估,从而得出体征的评估结果。

2 状态评估模型

2.1 理论基础

目前,“数据驱动”依赖大规模标注数据自动挖掘特征,虽泛化能力强,但缺乏可解释性且易受数据偏差影响。而“知识驱动”强调将领域专家知识与生

理机制作为先验知识,结构化融入模型设计。本文的“知识”具体为:一是基于意识障碍神经生理机制(如脑电慢波化、复杂度下降)构建 EEG 特征提取路径;二是基于自主神经功能评估方法(如 HRV 分析)设计 ECG 特征体系;三是模拟“先评估生命体征、后评估意识状态”的临床决策逻辑,构建层级化条件融合架构。通过将临床先验硬编码为网络结构与特征策略,实现了从“数据驱动”到“知识引导”的范式转换,使模型决策路径更贴近真实临床推理,提升评估的科学性与可信度。

系统理论基于昏迷与意识障碍的神经生理机制^[25]:意识水平降低常伴随脑电节律慢波化(δ 、 θ 波增强)与非线性动力学复杂度下降;自主神经功能失衡则表现为心率变异性(HRV)频谱改变;血氧饱和度持续下降反映组织氧合障碍。在信号处理层面,非线性动力学(如多尺度熵)可量化生理系统的调节能力,时频分析能捕捉瞬态节律变化。

临床评估遵循“先生命体征、后神经功能”的急救逻辑—循环与呼吸稳定是意识评估的前提^[23-24]。本文据此设计层级化融合架构:先融合心电与血氧特征生成“生命维持强度”上下文,再以此为条件引导脑电特征的深度解析,使模型决策路径与临床推理逻辑高度契合,为后续多模态融合提供科学依据。

2.2 数据集构建

为解决灾后救援中低唤醒人员易被误判为昏迷而导致生命风险评估失真的问题,本文在数据集构建上采用公共数据集与自主采集数据集相结合的方式。现有公共生命状态数据多来源于重症监护或心搏骤停后的明确昏迷患者,难以覆盖灾后环境中常见但易被忽视的“可唤醒”低唤醒状态。为弥补这一不足,本文将“可唤醒状态”作为一种独立的生命状态类型引入数据体系,并通过自主试验采集对应的多模态生理信号数据;同时,结合公开的心脏骤停后昏迷患者数据,对原有标签进行统一重构与分级。通过对两类数据集的融合,本文最终构建形成涵盖可唤醒、轻度昏迷、重度昏迷和近似死亡 4 种生命状态的多模态标签数据集,为灾后复杂环境下生命状态精细化识别与救援优先级判定提供数据基础。

1) 昏迷数据集介绍。The George B. Moody PhysioNet Challenge 2023 数据库收集了来自美国和欧洲 7 所学术医院的 1 000 余名成年心脏骤停患者数据,涵盖患者在恢复自发循环(ROSC)后仍处于持续昏迷状态并接受 ICU 监护期间的基线临床信息及

连续多模态生理信号。在此基础上,本文进一步统一数据截取策略,选取每位患者心搏骤停后第 24 h 内最初连续 5 min 的 EEG、ECG 与 SpO₂ 信号,共构建 2 000 份样本,形成适用于生命状态识别研究的轻度昏迷、重度昏迷与近似死亡 3 类多模态生命状态数据库。

2) 可唤醒数据集构建。本文所提出的“可唤醒”状态对应临床格拉斯哥昏迷量表(GCS)13~14 分,GCS 为 13~14 分表示患者处于清醒向昏迷过渡的临界状态。COLEMAN^[26]定义的最小意识状态(MCS)强调了“受试者对环境表现出非反射性的感知证据”,这与浅睡眠阶段 N2 期的外部响应逻辑完全吻合。临床观察表明脑损伤后的意识恢复往往伴随着生理性睡眠结构的重建^[27],证明浅睡眠与“可唤醒”状态在神经环路上共享了同一套调节机制。浅睡眠状态下表现出的心肺代谢率下降,有效模拟了矿井灾后因环境低氧导致的初期保护性代谢抑制。这种生理—病理特征的强关联,确保了模型在识别意识水平受损(而非单纯睡眠)时的泛化能力。

本研究围绕灾后低唤醒人员的生命状态建模需求,系统构建了“可唤醒”生命状态数据集。数据采集以健康成年人作为对象,共招募 20 名被试(男性 12 名,女性 8 名,年龄为 22~26 岁)。所有被试均无神经系统疾病史、无睡眠障碍、近期末服用精神类药物。试验前均已充分了解流程并签署知情同意书。在数据采集过程中,同步设置与昏迷数据一致的采样率、通道配置及预处理流程,以保证不同来源数据的可比性。数据采集在低光照、相对安静的室内环境中进行,被试保持半躺或平躺静息姿态,试验统一安排夜间约 22:00 开始,以利用生理疲劳和昼夜节律促进低唤醒状态的自然出现。每名被试在一次试验中完成约 60 min 的数据采集,流程包括清醒基线阶段(闭眼与睁眼静息各约 5 min)以及自然入睡阶段,在不施加任何药物干预的情况下连续记录生理信号,并每隔约 10 min 进行一次轻度唤醒检查。最终,通过严格的质量控制与标注流程,共获取 500 份同步 EEG、ECG 和 SpO₂ 的有效“可唤醒”生命状态数据。

2.3 特征提取

在多模态生命状态评估系统中,通过特征提取器从原始生理信号中提取关键信息。每个提取器均依据相应信号的生理生成机制与临床评估意义进行构建,旨在将高维、含噪的原始波形转化为低维、鲁棒且具有判别力的特征向量。

2.3.1 单通道 EEG 鲁棒特征提取

单通道前额 EEG 传感单元,在获取便捷性的同时,面临着信号空间信息缺失、伪迹污染严重(眼电、

肌电)等挑战。为此,本文设计了一个基于并行多路径分析的鲁棒特征提取器,其核心架构如图 2 所示。




图 2 单通道 EEG 鲁棒特征提取算法

Fig.2 Single-channel EEG robust feature extraction algorithm

1) 自适应预处理。原始信号首先经过 0.5 ~ 45.0 Hz 的巴特沃斯带通滤波,以保留与意识活动相关的有效频带并抑制基线漂移与高频噪声。随后,采用基于小波变换模极大值的算法检测瞬态伪迹(如眼电、眨眼)。对于被标记为伪迹的片段(A),利用其前后正常数据段建立自回归(AR)模型进行修复。

$$X_{\text{clean}}(t) = \begin{cases} \sum_{i=1}^p \phi_i X_{\text{normal}}(t-i) + \epsilon(t), & t \in A \\ X_{\text{filt}}(t), & \text{otherwise} \end{cases} \quad (1)$$

式中: X_{clean} 为处理后信号; p 为 AR 模型阶数; ϕ_i 为模型系数; $\epsilon(t)$ 为白噪声; X_{normal} 为相邻正常信号段; X_{filt} 为滤波后信号。

2) 并行多路径特征提取。为克服单通道空间信息不足的缺陷,本文从时频、非线性动力学及波形形态 3 个互补维度并行提取特征。

路径一: 高分辨率时频特征。采用复 Morlet 小波进行连续小波变换(CWT),获取高分辨率的时频谱 $W(a, b)$:

$$W(a, b) = \frac{1}{\sqrt{a}} \int X_{\text{clean}}(t) \psi^* \left(\frac{t-b}{a} \right) dt \quad (2)$$

其中, ψ^* 为母小波函数的复共轭运算; a 为尺度因子; b 为平移因子。从时频谱中提取以下特征: ① 4 个频带 (δ (0.5 ~ 4.0 Hz)、 θ (4.0 ~ 8.0 Hz)、 α (8.0 ~ 13.0 Hz)、 β (13.0 ~ 30.0 Hz)) 的相对功率占总功率的比例为 P_δ 、 P_θ 、 P_α 、 P_β ; ② 谱边缘频率(SEF95): 累积功率达到总功率 95% 时对应的频率,是意识水平降低的敏感指标; ③ 瞬时频率稳定性: 计算主导频带瞬时频率的方差(σ_{IF}^2)。

路径二: 非线性动力学特征。以多尺度样本熵(MSE)为例,首先构造粗粒度序列:

$$y^{(\tau)}(j) = \frac{1}{\tau} \sum_{i=(j-1)\tau+1}^{j\tau} X_{\text{clean}}(i) \quad (3)$$

其中, τ 为尺度因子。随后计算每个尺度下序列的样本熵:

$$\text{MSE}(\tau, m, r) = \text{SampEn}[y^{(\tau)}, m, r] = -\ln \frac{A^{(m)}(r)}{B^{(m)}(r)} \quad (4)$$

式中: m 为嵌入维数; r 为相似容限; $A^{(m)}$ 、 $B^{(m)}$ 分别为 $m+1$ 维和 m 维空间中的模板匹配数量,意识障碍时,复杂度降低,熵值衰减。

在具体参数设定上,考虑到 EEG 信号具有显著

的非线性、非平稳性及多分形特征,单一尺度下的熵值仅能反映高频随机噪声,难以捕捉深层次的动力学演化。本文将尺度设定为 $1 \sim 20$,旨在覆盖从高频 β 节律到低频 δ 慢波的完整特征空间,以精准捕捉意识受损时脑电能量向低频漂移的非线性表征。此外,嵌入维数 m 取 2,结合自适应容限 r 设为 0.15 倍的原始序列标准差,是在保障生物电信号统计有效性的前提下,平衡了计算效率与对微小病理波动敏感度的最优配置。

递归定量分析(RQA)是通过相空间重构生成递归图 $R(i, j) = \Theta(\epsilon - \|Y_i - Y_j\|)$,从中提取确定性(DET)、层平均长度(LAM)等特征,量化信号确定性程度。

去趋势波动分析(DFA),通过计算标度指数 α ,揭示信号的长程相关性。

路径三:瞬态波形形态特征。多尺度一维卷积:使用 3 个不同宽度(50、100、250 ms)的一维卷积核对信号进行卷积,以捕获与特定神经振荡(如慢波)相关的局部波形模式。

瞬态慢波事件统计:检测幅度超过阈值、持续时间为 $0.5 \sim 2.0$ s 的负向偏转波,统计其平均幅度与发生率(次/min)。慢波活动的增强是意识水平下降的标志之一。

3)特征融合与降维。将 3 条路径提取的所有标量特征拼接成高维向量。随后,引入一个轻量的特征级注意力层,为不同特征分配可学习的权重,实现自适应加权,最后,通过一个全连接层进行降维与非线性变换,输出最终的 EEG 特征向量 F_{ecg} 。

2.3.2 ECG 自主神经功能特征提取

心电信号是评估心脏自主神经张力的黄金标准。本提取器旨在从单导联 ECG 中精确量化心率变异性(HRV)及心搏波形形态。

1) R 峰检测与波形分割。对 ECG 进行预处理与 R 峰检测,信号经 $1 \sim 40$ Hz 带通滤波后,采用经典的 Pan-Tompkins 算法实时检测 R 峰位置,得到 R 峰时间点序列 $(t_{R,i=1,2,\dots,M})$ 。由此计算相邻 R 峰的时间间隔,形成 R-R 间期序列: $RR_i = t_{R,i+1} - t_{R,i}$ 。

2) 双分支特征提取。双分支分别指心率变异性 HRV 特征提取,以及波形形态特征提取。

分支一,HRV 特征从时域、频域和非线性 3 个层面进行刻画。时域特征包括全部正常 R-R 间期的标准差,表征副交感神经活性的敏感性,反映总体变异性,以及相邻 R-R 间期差值大于 50 ms 的个数所占百分比。频域特征方面,针对非均匀采样的 R-R 间期序列,采用 Lomb-Scargle 周期图法进行谱估计,

避免重采样带来的信息失真。计算低频功率(LF, $0.04 \sim 0.15$ Hz),用于反映交感与副交感神经的共同调节;高频功率(HF, $0.15 \sim 0.4$ Hz),与呼吸性心律不齐相关,主要反映副交感神经活性;LF/HF 比值:表征交感-迷走神经平衡。非线性特征方面,包括庞加莱图分析,序列样本熵(方法同脑电)计算,用于度量心率节奏的复杂性。

对于心搏波形形态特征提取,以每个 R 峰为基准点,截取固定时间窗(如 R 峰前 100 ms 至后 400 ms)的心搏波形,并进行幅值和时间对齐,生成平均心搏波形。随后,使用一个浅层的一维卷积神经网络(1D CNN)自动学习平均波形的形态学特征(如 P 波、T 波形态,ST 段趋势等),输出形态特征向量。

其网络结构设计依据在于:心电信号的形态学特征主要集中于 QRS 波群,其在特定采样率下的时间跨度决定了特征提取的空间域需求。本文采用卷积核大小交替为 3 和 5 的多尺度一维卷积网络,通过小卷积核叠加形成较大的感受野,旨在精准捕捉 R 峰及其前后切迹的微小形态畸变,这对于评估矿井环境下心脏电生理的稳定性具有重要的物理意义。同时,卷积层通道数采用 [16, 32, 64] 的逐层递增设计,严格遵循了从低阶空间波形到高阶抽象病理特征提取的表征学习逻辑。

3)特征融合与降维。将 HRV 的时域、频域、非线性特征向量与波形形态特征向量进行拼接,通过一个全连接层进行融合与降维,输出最终的 ECG 特征向量 $(F_{\text{ecg}} \in \mathbb{R}^{d_c})$ 。

2.3.3 SpO₂ 氧合趋势特征提取

血氧饱和度信号反映了组织的氧供情况。本提取器旨在从可能存在运动伪影和缺失值的数值序列中,提取反映氧合稳定性、下降趋势及潜在风险的统计与动态特征。

1) 数据清洗与序列重构。原始 SpO₂ 信号易受运动伪影影响而产生骤降或缺失(参考文献)。首先,基于中位数绝对偏差(MAD)方法识别并剔除幅度异常点。对于缺失或被剔除的数据点,采用线性插值进行补全。最后,应用一个窗口长度为 5 s 的滑动平均滤波器对序列进行平滑,以抑制高频噪声,得到高质量序列 $X_{\text{smooth}}(t)$ 。

2) 多角度趋势特征提取。先是全局统计特征,主要计算序列的整体描述性统计量,包括中心趋势与离散度(均值 μ_{SpO_2})、标准差 (σ_{SpO_2})、四分位距(IQR);缺氧负荷量化,计算血氧值低于临床关键阈值的时间占比,以及累积缺氧面积,综合反映缺氧的

深度与持续时间。

其次是滑动趋势特征提取,包括趋势斜率分析,即在30 s的滑动窗口内,对序列进行线性回归,得到局部斜率 k_i 。计算所有窗口斜率的均值 $\bar{k}$ 和方差 σ_k^2 ,以评估整体的氧合变化趋势及其波动性。然后针对窗口统计序列,计算10 s滑动窗口内的均值和标准差,形成2个新的时间序列 $\mu_w(t)$ 和 $\sigma_w(t)$,再对这2个序列计算其均值、方差等统计量,以刻画氧合状态的短时波动模式。

第三是时序动态特征提取,将平滑后的序列(X_{smooth})输入一个双向门控循环单元(Bi-GRU)网络。GRU的循环结构使其能够有效建模时间序列中的长程依赖关系。血氧饱和度作为反映机体氧合状态的低频趋势信号,其变化具有显著的时间依赖性与长程相关性。因此,本文选用隐藏层维度为64的Bi-GRU结构,既能够有效记忆分钟量级的血氧波动趋势,又在有限样本下避免了高维参数导致的过拟合风险。双向结构的设计利用了血氧下降过程中的因果逻辑,能够同时捕捉当前时刻前后文关联。最终,取最后一个时间步的双向隐状态进行拼接,形成编码了整个序列动态上下文信息的特征向量。

3)特征融合与降维。将全局统计特征、滑动趋势特征的统计量以及GRU的动态特征进行拼接,形成综合特征向量。随后通过一个全连接层进行降维,输出最终的 SpO_2 特征向量($F_{\text{spO}_2} \in \mathbb{R}^{d_s}$)。

以上3个模态专用特征提取器,分别针对各自

信号的生理特性,设计了具有针对性的处理流程与特征集合。它们将原始信号转化为高质量的特征向量,为层级化融合与状态评估提供了可靠的信息输入。所有特征的设计均以可解释性和临床相关性为重要考量,确保了模型决策基础的合理性。

2.4 条件化层级融合

层级化条件融合模型旨在模拟急救医学中“先稳固生命体征,后评估神经功能”的临床决策逻辑^[20-21],通过结构化的编码器设计与条件化注意力机制,实现多模态生理信号由浅入深、由基础到高级的信息融合与状态推理。

模型的输入为3个模态专用特征提取器的输出:EEG特征向量 $F_{\text{ecg}} \in \mathbb{R}^{d_e}$, ECG特征向量 $F_{\text{ecg}} \in \mathbb{R}^{d_c}$,以及 SpO_2 特征向量($F_{\text{spO}_2} \in \mathbb{R}^{d_s}$),其中 d_e 、 d_c 、 d_s 分别代表脑电、心电和血氧的参数维度。整体处理流程分为2个核心阶段,如图3所示。遵循救援医学的优先级,即优先保障循环与呼吸(生命维持系统),在此基础上再评估中枢神经系统损伤程度。本模型将这一领域知识硬编码为网络结构。第一阶段(生存体征融合),首先融合反映心肺功能的ECG与 SpO_2 特征,生成一个综合的、低维的“生命维持状态”上下文向量 V_{survival} 。第二阶段(神经状态条件融合):将 V_{survival} 作为全局条件,引导对EEG(反映脑功能)特征的深度解析与融合。此时,模型对脑电活动的“注意力”会因其生命维持状态的不同而动态调整。

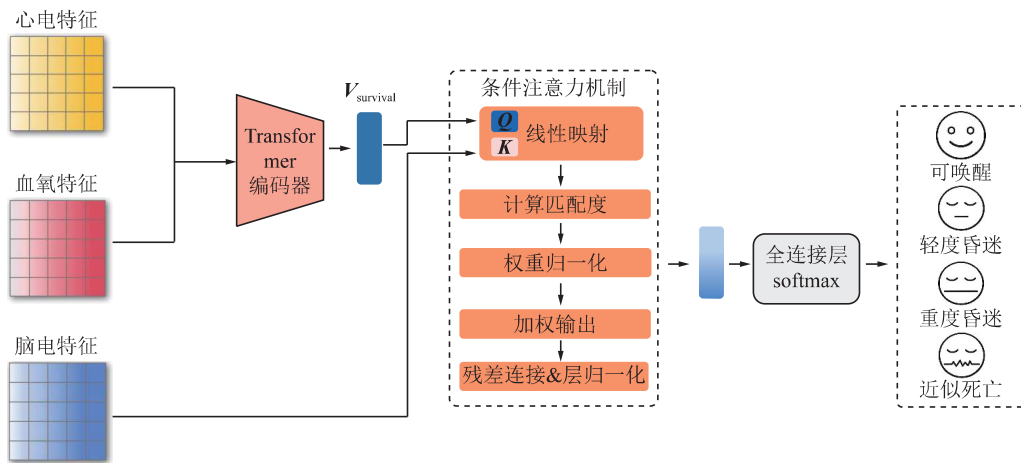


图3 层级化条件融合模型

Fig.3 Hierarchical conditional fusion model

2.4.1 生存体征融合

该编码器目标是将 F_{ecg} 和 F_{spO_2} 融合,生成表征基础生命力的上下文向量。主要由2个步骤组成。

1)模态特定投影与序列化。将不同维度的特征

投影到统一的模型维度(d_{model}):

$$E_c = W_c F_{\text{ecg}} + b_c, E_s = W_s F_{\text{spO}_2} + b_s, E_c, E_s \in \mathbb{R}^{d_{\text{model}}} \quad (5)$$

将投影后的特征视为一个长度为2的序列:

$Z^{(0)} = [E_e; E_s] \in \mathbb{R}^{2d_{\text{model}}}$ 。添加可学习的位置编码 ($P \in \mathbb{R}^{2d_{\text{model}}}$) 以注入序列顺序信息: $Z^{(0)} := Z^{(0)} + P$ 。

2) Transformer 编码。将序列 ($Z^{(0)} \in \mathbb{R}^{2d_{\text{model}}}$) 输入一个由 4 层标准 Transformer 编码器堆叠的模块, 如图 4 所示。对于第 1 层 ($l = 1, 2, \dots, L$), 其前向传播过程如下。

多头自注意力机制的计算过程如下, 每个注意力头(head_{*i*})的计算式为

$$\text{head}_i = \text{Attention}(Q_i, K_i, V_i) = \text{softmax}\left(\frac{Q_i K_i^T}{\sqrt{d_k}}\right) V_i \quad (6)$$

$$Q_i = Z^{(l-1)} W_i^Q, \quad K_i = Z^{(l-1)} W_i^K, \quad V_i = Z^{(l-1)} W_i^V \quad (7)$$

式中: $Z^{(l-1)}$ 为第 l 层编码器的输入, 也是第 $l-1$ 层的输出; h 为注意力头的总数; $d_k = d_{\text{model}}/h$ 为每个注意力头的键向量和查询向量的维度。

$W_i^Q, W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$: 第 i 个头用于生成查询 Q_i 和键 (K_i) 的可学习权重矩阵。 $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$: 第 i 个头用于生成值 (V_i) 的可学习权重矩阵, 通常 $d_v = d_k$, d_v 和 d_k 分别为注意力机制中 value 和 key 的向量维度。 $W^O \in \mathbb{R}^{(h \cdot d_v) \times d_{\text{model}}}$: 用于将拼接后的多个注意力头输出投影回模型维度的可学习权重矩阵。

随后进行残差连接与层归一化:

$$Z^{(l)} = \text{LayerNorm}(Z^{(l-1)} + \text{MHA}(Z^{(l-1)})) \quad (8)$$

式中: $\text{LayerNorm}(\cdot)$ 为层归一化操作, 对输入张量在最后一个维度 (特征维度 d_{model}) 上进行均值为 0、方差为 1 的标准化, 并引入可学习的缩放和平移参数; $Z^{(l)}$ 为经过多头自注意力及残差连接、层归一化后的

中间表示。

最后为前馈网络与再次归一化, 前馈网络由 2 个线性变换和一个非线性激活函数组成:

$$\text{FFN}(Z^{(l)}) = \text{ReLU}(Z^{(l)} W_1^{(l)} + b_1^{(l)}) W_2^{(l)} + b_2^{(l)} \quad (9)$$

再次进行残差连接与层归一化:

$$Z^{(l)} = \text{LayerNorm}(Z^{(l)} + \text{FFN}(Z^{(l)})) \quad (10)$$

式中: $W_1^{(l)} \in \mathbb{R}^{d_{\text{model}} \times d_{\text{ffn}}}$, $b_1^{(l)} \in \mathbb{R}^{d_{\text{ffn}}}$ 为第 l 层前馈网络中第一个线性变换的权重和偏置; d_{ffn} 通常为 $4 \times d_{\text{model}}$ 。 $W_2^{(l)} \in \mathbb{R}^{d_{\text{ffn}} \times d_{\text{model}}}$, $b_2^{(l)} \in \mathbb{R}^{d_{\text{model}}}$ 为第 l 层前馈网络中第二个线性变换的权重和偏置; $\text{ReLU}(\cdot)$ 为修正线性单元激活函数, 定义为 $\text{ReLU}(x) = \max(0, x)$; $Z^{(l)}$ 为第 l 层 Transformer 编码器的最终输出, 将作为第 $l+1$ 层的输入。

这些公式与定义共同构成了生存体征融合编码器中多层 Transformer 编码的完整、闭环的数学描述。整个流程从 $Z^{(0)}$ 开始, 逐层传递, 最终得到包含丰富交互信息的 $Z^{(L)}$, 为后续生成上下文向量 V_{survival} 奠定了基础。

2.4.2 神经状态条件融合

该阶段是本模型的核心创新, 旨在以 V_{survival} 为条件, 对 EEG 特征进行深度、有侧重的融合。

1) EEG 特征投影与条件化准备。 E_e 将 EEG 特征投影到模型空间同时, 将上下文向量 V_{survival} 通过一个线性层映射到同等维度, 并复制 T_e (EEG 特征序列长度) 份, 若 E_e 为单向量则 ($T_e = 1$), 形成条件序列 $C \in \mathbb{R}^{T_e \times d_{\text{model}}}$ 。

2) 条件化 Transformer 编码层。这是实现“条件融合”的关键。本文设计了条件化多头自注意力模块来替代标准 MHA。对于第 l 层的输入 $S^{(l-1)}$ (初始时 $S^{(0)} = E_e + P_e$)。

条件化键值生成: 不再从 $S^{(l-1)}$ 自身生成键 K 和 V , 而是将生存状态条件 C 与当前 EEG 表示进行融合后生成。

$$H^{(l-1)} = S^{(l-1)} + C, \quad K^{(l)} = H^{(l-1)} W_k^l, \quad V^{(l)} = H^{(l-1)} W_v^l \quad (11)$$

查询生成: 查询向量 Q 仍来自原始的 EEG 表示 $S^{(l-1)}$, 以确保注意力机制的核心仍是 EEG 信号本身。

条件化注意力为

$$\text{CA}(Q^{(l)}, K^{(l)}, V^{(l)}) = \text{softmax}\left(\frac{Q^{(l)} (K^{(l)})^T}{\sqrt{d_k}}\right) V^{(l)} \quad (12)$$

模型在计算 EEG 内部各元素间注意力时, 其用于匹配和聚合信息的“字典” (K, V) 已经根据生命维持状态 V_{survival} 进行了重写。例如, 当 V_{survival} 指示严重




图 4 Transformer 编码器

Fig.4 Transformer encoder

低血氧时, K 和 V 会更倾向于强调 EEG 中与缺氧性脑损伤相关的模式特征。

后续的残差连接、层归一化及前馈网络步骤与标准 Transformer 相同。堆叠 N 层这样的条件化编码层后, 得到高级融合表示 $S^{(N)}$ 。

融合特征: 对 $S^{(N)}$ 进行全局平均池化, 得到最终的、蕴含了多模态信息与层级化决策逻辑的融合特征向量:

$$F_{\text{fused}} = \text{Mean}(S^{(N)}) \in R^{d_{\text{model}}} \quad (13)$$

决策输出: 至此, 模型完成了从原始多模态信号到高级融合特征的完整的推理链。最终, 将 F_{fused} 输入一个简单的多层感知机分类器:

$$\hat{y} = \text{Softmax}[W_c \cdot \text{ReLU}(W_f F_{\text{fused}} + b_f) + b_c] \quad (14)$$

式中: $\hat{y}$ 为模型预测的生命状态概率分布, 对应于“可唤醒”“轻度昏迷”“重度昏迷”“近似死亡”4个类别。

3 结果分析

在数据集预处理完成之后, 将数据输入模型中进行训练。数据集包含 2 500 份有效样本, 并按照 8:2 的比例划分为训练集和测试集。离线测试过程中, 采用 Adam 优化器, 以交叉熵损失函数作为优化目标, 批处理大小设置为 16。初始学习率设为 0.001, 并在训练过程中引入动态学习率调整机制, 随着训练迭代的推进逐步降低学习率, 以增强模型在后期训练阶段的收敛稳定性和泛化能力。

训练过程总计迭代 100 个 Epoch, 经离线测试得到模型最终预测结果。图 5、图 6 分别展示了不同模态组合模型在 100 次迭代内的准确率与损失值变化趋势。从图 5 可以看出, 各模型在训练初期准确率均呈现快速上升趋势, 其中三模态融合模型在整个训练过程中始终保持最高的准确率水平, 其准确率在约第 40 次迭代后逐渐趋于稳定, 并最终稳定在 0.94 左右; 双模态模型(心电+血氧)的准确率次之, 最终收敛至约 0.87; 单模态模型中, 心电信号的识别效果优于脑电和血氧信号, 最终准确率约为 0.78, 而脑电与血氧单模态模型的准确率相对较低, 分别稳定在 0.74 和 0.72 左右。整体来看, 多模态融合模型在准确率上明显优于单模态模型, 图 6 给出了对应的损失值变化情况。可以观察到, 所有模型的损失值在训练初期均快速下降, 随后逐渐趋于平稳。其中, 三模态融合模型的损失值下降速度最快, 在约第 35 次迭代后即收敛至较低水平, 并长期稳定在 0.05

以下; 双模态模型的最终损失值约为 0.10, 明显低于各单模态模型。相比之下, 单模态模型的损失值收敛较慢, 且稳定值较高, 其中血氧单模态模型的损失值波动相对较大, 最终稳定在 0.33 左右, 而脑电和心电单模态模型的损失值分别约为 0.25 和 0.23。




图 5 迭代 100 次后的准确率变化曲线

Fig.5 Accuracy curves after 100 iterations




图 6 迭代 100 次后的损失值变化曲线

Fig.6 Loss value change curves after 100 iterations

表 1 展示了不同生理信号模态组合对 4 种生命状态(可唤醒、轻度昏迷、重度昏迷、近似死亡)的分类准确率。从单一模态到多模态融合的递进比较, 切实地验证了“层级化条件融合编码器”模型的有效性。单一模态(脑电、心电或血氧)的平均准确率范围为 72.33% 至 78.04%, 且各自存在明显的评估盲区。例如, 仅使用脑电时, 对“近似死亡”状态的识别率最低(68.18%); 而仅用心电时, 对“轻度昏迷”的识别率较弱(72.56%)。从表中数据可以看出, 模型性能与模态信息的丰富度呈正相关, 说明单一生理信号在全面评估复杂生命状态时存在固有的局限性。

表 2 呈现了不同模态组合下的召回率性能, 召回率的变化趋势与准确率一致。在单模态条件下, 各模型的平均召回率(70.91% ~ 78.55%)与准确率水平相当, 但同样表现出对不同状态敏感性的差异。单一血氧模态对“重度昏迷”的召回率最低(66.86%), 而单一心电模态对“近似死亡”的召回率最高(83.46%)。

表 1 不同模态下的分类准确率
Table 1 Classification accuracy under different modalities

模态	分类准确率/%				
	可唤醒	轻度昏迷	重度昏迷	近似死亡	平均值
脑电	82.45	76.30	73.15	68.18	75.02
心电	80.25	72.56	76.80	82.55	78.04
血氧	74.86	68.50	66.75	79.20	72.33
心电+血氧	92.60	84.80	89.20	85.40	88.00
脑电+心电+血氧	95.85	93.56	94.40	95.79	94.90

表 2 在不同模态下的召回率
Table 2 Recall under different modes

模态	召回率/%				
	可唤醒	轻度昏迷	重度昏迷	近似死亡	平均值
脑电	80.93	74.98	75.62	67.21	74.69
心电	78.38	74.21	78.13	83.46	78.55
血氧	71.68	68.13	66.86	76.95	70.91
心电+血氧	90.25	82.88	88.20	88.10	87.36
脑电+心电+血氧	93.84	94.66	91.86	96.83	94.30

这可以表明不同生理信号在病理生理学意义上的侧重不同,单一信号难以全面捕捉所有状态特征。心电与血氧的双模态融合将平均召回率提升至 87.36%,且各类别召回率均提升至 82.88% 以上。这标志着模型整体检全能力的实质性增强,说明生命体征的融合有效扩展了模型的感知边界,减少了对单一状态(尤其是危重状态)的漏判。

表 3 为不同融合策略下各生命状态的消融试验结果。简单的多模态特征拼接(平均准确率仅为

88.40%)忽视了心肺与脑电信号间显著的模态异质性,导致模型在高度交叠的特征空间中发生表征冲突;而扁平化自注意力机制虽通过全局交互将平均准确率提升至 91.78%,却因将各输入模态视为平权序列,缺失了灾难医学中“生存体征优先于意识体征”的关键结构先验。相比之下,本文提出的层级化条件融合模型取得了最优的综合评估性能(平均准确率 94.89%),尤其在关键的“可唤醒”状态识别上准确率高达 95.85%。

表 3 不同融合策略下三模态各生命状态准确率
Table 3 Accuracy of three modal life states under different fusion strategies

融合策略	准确率/%				
	可唤醒	轻度昏迷	重度昏迷	近似死亡	平均值
直接拼接特征	89.15	86.40	87.25	90.80	88.40
扁平化自注意力机制	92.40	90.15	91.30	93.25	91.78
本文方法	95.85	93.56	94.40	95.79	94.90

全模态融合模型取得了 94.30% 的平均召回率,为所有配置中最高。尤为重要的是,其在所有 4 个生命状态上的召回率均表现优异且均衡(91.86%-96.83%)。这一结果表明本文的层级化条件融合策略不仅提升了整体精度,更增强了模型在各个类别上的泛化能力和可靠性。

高召回率与高准确率的同步达成,共同证明了该融合框架能够生成判别力强、泛化性好的融合特征表征,从而在矿井应急救援等对漏报和误报都极为敏感的场景中,展现出重要的应用潜力。

为更充分地验证本文方法的性能优势,在相同试验条件下,本研究将本文模型与 CNN-Transformer、


MuKAT 及 TB-CAT 等主流架构进行了系统性对比。各模型的平均准确率与召回率对比汇总见表 4。借助图表的联合分析,本文方法在整体分类精度与边界状态泛化能力上的突破性提升得以直观显现。

从表 4 可以看出,本文模型取得了 94.90% 的平均准确率与 94.30% 的平均召回率,优于 CNN-Transformer、MuKAT 及 TB-CAT 等对比模型(对比模型最高平均准确率为 88.08%),有助于降低矿井救援场景下的漏诊风险。结合图 7 的混淆矩阵进一步分析,常规数据驱动模型在特征交叠较多的“轻度昏迷”与“重度昏迷”状态上容易出现交叉误判,识别准确率多在 80% 左右徘徊。相比之下,本文方法在各单一

表 4 不同评估模型的平均准确率与召回率对比
Table 4 Comparison of average accuracy and recall rates across different evaluation models

评估模型	平均准确率/%	平均召回率/%
CNN-Transformer	77.30	76.50
MuKAT	81.88	81.20
TB-CAT	88.08	87.60
本文方法	94.90	94.30

类别上的准确率均达到 93% 以上,特别是在上述 2 个易混淆类别上的准确率分别达到了 93.56% 和 94.40%,有效改善了模糊状态的识别效果。



注: (1)(2)(3)(4)为 4 种生命状态, (1)为可唤醒, (2)为轻度昏迷, (3)为重度昏迷, (4)为近似死亡。

图 7 不同模型混淆矩阵图

Fig.7 Confusion matrix diagram for different models

综上所述,上述性能指标表明了本文设计的合理性—将临床先验知识结构化嵌入层级融合架构,能够有效减少模糊病理状态的特征误判,在生命状态评估任务中具有较好的可靠性与应用潜力。

4 结论与展望

4.1 结 论

1) 通过在矿井救援场景中明确定义并引入“可

唤醒”状态,将生命状态评估扩展为一个精细化的连续谱系分类问题。在此基础上,为脑电、心电、血氧信号量身定制了与之高度相关的专用特征体系(如用于区分意识细微差别的脑电非线性特征、用于预警恶化的血氧趋势特征),而非套用现有通用特征集。试验结果证实,这种针对特定科学问题的原生特征设计,是模型取得高判别精度(平均准确率 94.90%)的根本原因。

2) 面对单通道前额 EEG 空间信息完全缺失的问题,所提出的“深度时序信息挖掘”框架通过并行融合时频、非线性动力学及形态学分析,以时序维度的“深度”弥补了空间维度的“广度”,实现对意识状态“有序度”与复杂度的精细刻画。同时,信号预处理中针对性的伪迹检测与修复机制,增强算法在灾后噪声环境下的鲁棒性。

3) 设计特征提取器与后续的层级化条件融合模型形成了有机整体:特征提取服务于“先生存、后神经”的融合逻辑,而融合模型又依赖于特征提供的互补且可解释的生理信息。该闭环系统在标准数据集上验证了其高精度与高鲁棒性,为矿山应急救援装备的智能化升级提供了可直接落地的核心算法原型。

4.2 展 望

1) 针对矿井应急救援的实际应用需求,后续研究将从以下 3 方面深化:首先,提升算法鲁棒性,引入改进的集成经验模态分解与信号质量评估机制,抑制强电磁干扰及运动伪影;其次,面向嵌入式平台进行轻量化优化,通过模型剪枝与量化压缩降低计算负载,实现在低功耗控制器上的实时推理;最后,联合医疗机构采集真实病理数据,增强模型对复杂场景下人员昏迷状态的泛化能力。

2) 特别是针对本文利用浅睡眠模拟的“可唤醒”状态,由于真实灾后环境往往伴随缺氧及急性应激,其生理表征更为复杂,后续的深入研究将致力于突破现场采集的现实与伦理瓶颈。计划依托矿山应急救援基地的实景演练,以及与定点收治医院急诊科建立的灾后伤员生理数据库,逐步积累并引入真实矿井救援场景下的“可唤醒”多模态数据集。通过真实数据的闭环验证与模型微调,进一步夯实该评估系统在受限环境下的准确率与可靠性。

参考文献(References):

- [1] 陈晓晶,邢震,包建军,等. 矿山“感知-通信-决策-控制”一体化框架下人工智能应用综述[J/OL]. 煤炭科学技术, 1-19 [2025-12-19]. <https://link.cnki.net/urlid/11.2402.TD.20250922.2034.002>.
- [2] 王飞. 基于光纤传感技术的智能矿山无人化巡检系统研究[J]. 煤炭科学技术, 2021, 49(S2): 263-267.
- [3] 郑学召,马扬,黄渊,等. 面向矿山救援的 UWB 雷达生命信息识别研究现状与展望[J]. 工矿自动化, 2024, 50(7): 12-20.
- [4] 文虎,唐瑞,刘名阳,等. 矿山生命信息探测仪在事故救援中的应用[J]. 煤矿安全, 2022, 53(4): 162-166.
- [5] CHEN Z H, MIAO Y Y, WANG L Y, et al. Versatile cardiovascular signal generation with a unified diffusion transformer[J]. *Nature Machine Intelligence*, 2026, 8(1): 6-19.
- [6] WANG M X, LI Z Y, TIAN Y Y, et al. BioCross: A cross-modal framework for unified representation of multi-modal biosignals with heterogeneous metadata fusion[J]. *Information Fusion*, 2025, 123: 103302.
- [7] YAO W H, LYU Z H, MAHMUD M, et al. CATD: Unified representation learning for EEG-to-fMRI cross-modal generation[J]. *IEEE Transactions on Medical Imaging*, 2025, 44(7): 2757-2767.
- [8] 曹现刚,刘航,刘家辉,等. 面向原煤分选场景的多模态融合异物开集检测方法[J]. 煤炭科学技术, 2026, 54(1): 464-474.
- [9] 刘光伟,雷健,郭直清,等. 面向跨模态的露天矿障碍物检测方法[J]. 煤炭科学技术, 2025, 53(11): 327-340.
- [10] XU S Y, ZHANG S J. Application of multi-scale spatiotemporal networks in physiological signal and facial action unit measurement[J]. *Journal of Biomedical Engineering*, 2025, 42(3): 552-559.
- [11] CHEN D Y, SHI J, TAO B, et al. A novel transfer learning-based hybrid EEG-fNIRS brain-computer interface for intracerebral hemorrhage rehabilitation[J]. *Advanced Science*, 2025, 12(43): e05426.
- [12] SUN C Z, MOU C Z. Survey on the research direction of EEG-based signal processing[J]. *Frontiers in Neuroscience*, 2023, 17: 1203059.
- [13] LI J J, WANG Q. Multi-modal bioelectrical signal fusion analysis

- is based on different acquisition devices and scene settings; Overview, challenges, and novel orientation[J]. *Information Fusion*, 2022, 79: 229–247.
- [14] WAN X, WANG Y X, WANG Z, et al. Joint low-rank tensor fusion and cross-modal attention for multimodal physiological signals based emotion recognition[J]. *Physiological Measurement*, 2024, 45(7): 075003.
- [15] LIANG Y T, LIU Y J, LU C J, et al. Research on intelligent monitoring and protection equipment of vital signs of underground personnel in coal mines: Review[J]. *Sensors*, 2025, 25(1): 63.
- [16] LI X C, ZHANG S H, LI X W, et al. SHAP-driven insights into multimodal data: Behavior phase prediction for industrial safety applications[J]. *Scientific Reports*, 2025, 15: 34965.
- [17] 朱崇智, 邵玉斌, 杜庆治, 等. 改进的多模态 Transformer 用于未对齐序列情感识别 [J/OL]. 重庆邮电大学学报(自然科学版), 1–11[2025–12–19]. <https://link.cnki.net/urlid/50.1181.n.20251224.1229.008>.
- ZHU Chongzhi, SHAO Yubin, DU Qingzhi, et al. Improved multimodal transformer for emotion recognition of misaligned sequences[J/OL]. *Journal of Chongqing University of Posts and Telecommunications (Natural Science Edition)*, 1–11[2025–12–19]. <https://link.cnki.net/urlid/50.1181.n.20251224.1229.008>.
- [18] TANG X Y, HUANG J Z, LIN Y X, et al. Speech Emotion Recognition via CNN-Transformer and multidimensional attention mechanism[J]. *Speech Communication*, 2025, 171: 103242.
- [19] 李嘉华, 陈景霞, 白义民. 基于 TCN-Bi-GRU 和交叉注意 Transformer 的多模态情感识别[J]. *陕西科技大学学报*, 2025, 43(1): 161–168.
- LI Jiahua, CHEN Jingxia, BAI Yimin. Multimodal emotion recognition based on TCN-Bi-GRU and cross attention Transformer[J]. *Journal of Shaanxi University of Science & Technology*, 2025, 43(1): 161–168.
- [20] ABU-SALIH B, AL-QURISHI M, ALWESHAH M, et al. Healthcare knowledge graph construction: A systematic review of the state-of-the-art, open issues, and opportunities[J]. *Journal of Big Data*, 2023, 10(1): 81.
- [21] FAN C C, ELAZAB A, ZHANG S Q, et al. Clinical Prior Guided Cross-Modal Hierarchical Fusion for Histological Subtyping of Lung Cancer in CT Scans[C]//GEE J C, ALEXANDER D C, HONG J, et al. Medical image computing and computer assisted intervention–MICCAI 2025. Cham: Springer Nature Switzerland, 2026: 75–84.
- [22] YU J L, RU Y D, LEI B J, et al. GBV-net: Hierarchical fusion of facial expressions and physiological signals for multimodal emotion recognition[J]. *Sensors*, 2025, 25(20): 6397.
- [23] CECCONI M, DE BACKER D, ANTONELLI M, et al. Consensus on circulatory shock and hemodynamic monitoring. Task force of the European Society of Intensive Care Medicine[J]. *Intensive Care Medicine*, 2014, 40(12): 1795–1815.
- [24] 曾莉萍. 早期预警评分用于神经系统疾病的研究进展[J]. *现代医药卫生*, 2023, 39(8): 1380–1384.
- ZENG Liping. Research progress of early warning score for nervous system diseases[J]. *Journal of Modern Medicine & Health*, 2023, 39(8): 1380–1384.
- [25] FRIDMAN E A, SCHIFF N D. Organizing a rational approach to treatments of disorders of consciousness using the anterior forebrain mesocircuit model[J]. *Journal of Clinical Neurophysiology*, 2022, 39(1): 40–48.
- [26] COLEMAN D. The minimally conscious state: Definition and diagnostic criteria[J]. *Neurology*, 2002, 58(3): 506–507.
- [27] DUCLOS C, DUMONT M, ARBOUR C, et al. Parallel recovery of consciousness and sleep in acute traumatic brain injury[J]. *Neurology*, 2017, 88(3): 268–275.